

Przewidywanie Pogody na Podstawie Danych Historycznych

Sieci Neuronowe 2024/2025

Hubert Malinowski, Maciej Karaśkiewicz

January 25, 2025

Spis Treści

- 1 Wprowadzenie
- 2 Opis modelu
- 3 Hipotezy Badawcze
- 4 Kodowanie Danych
- 5 Architektura Sieci
- 6 Architektura dla Danych Znormalizowanych
- 7 Funkcje Aktywacji
- 8 Ogólne Wnioski
- 9 Podziękowania

Cel projektu: Stworzenie modeli opartych na sieciach neuronowych do przewidywania dwóch aspektów pogody:

- Średnia dzienna temperatura (z dokładnością do 2°C).
- Wystąpienie silnego wiatru ($\geq 6 \text{ m/s}$ w ciągu dnia).

Wyzwanie: Prognoza na dzień jutrzejszy ($n + 1$) na podstawie danych z trzech poprzednich dni, z pominięciem dnia bieżącego (n).

W projekcie wykorzystano model bazowy, który posłużył jako punkt odniesienia w badaniach. Model składał się z:

- Warstw ukrytych z funkcją aktywacji ReLU.
- Dwóch wyjść:
 - Regresja średniej dziennej temperatury.
 - Klasyfikacja wystąpienia silnego wiatru.

Funkcje strat:

- MSELoss dla temperatury.
- BCELoss dla wiatru.

Optymalizacja: Adam, $\text{lr} = 0.01$.

Hipotezy zostały podzielone na cztery główne kategorie:

- ❶ **Kodowanie danych:** Wpływ normalizacji na skuteczność modeli.
- ❷ **Architektura sieci:** Porównanie pojedynczej sieci i oddzielnych modeli dla temperatury i wiatru.
- ❸ **Architektura dla danych znormalizowanych:** Ocena wpływu normalizacji w połączeniu z różnymi architekturami.
- ❹ **Funkcje aktywacji:** Porównanie funkcji ReLU i tanh jako funkcji aktywacji w warstwie ukrytej.


Hipoteza: Normalizacja danych wejściowych do przedziału $[-1, 1]$ poprawi skuteczność uczenia w porównaniu do danych nieznormalizowanych.

Wnioski:

- Normalizacja miała ograniczony wpływ na regresję temperatury.
- Klasyfikacja wiatru dopasowywała się do danych treningowych po normalizacji, co pogarszało wyniki dla danych testowych.


Dane Znormalizowane

Rzeczywista vs Przewidywana Temperatura w Czasie dla Vancouver - MAE: 1.18




Dane Nieznormalizowane


Rzeczywista vs Przewidywana Temperatura w Czasie dla Vancouver - MAE: 1.35



Macierz Konfuzji dla Klasyfikacji Wiatru w Vancouver - Test



Dane Nieznormalizowane




Hipoteza: Oddzielne modele dla temperatury i wiatru zapewnia lepsze wyniki niż pojedyncza sieć.

Wnioski:


- Rozdzielenie modeli spowodowało brak uczenia sie wiatru.
- Dla temperatury wyniki były porównywalne z pojedyncza siecia.

Dane Nieznormalizowane

Rzeczywista vs Przewidywana Temperatura w Czasie dla Vancouver - MAE: 1.35



Dane Nieznormalizowane




Hipoteza: Zastosowanie normalizacji w połączeniu z oddzielnymi modelami poprawi jakość predykcji.

Wnioski:


- Normalizacja spowodowała, że klasyfikacja wiatru dopasowywała się do danych treningowych po normalizacji, co pogarszało wyniki dla danych testowych.
- Dla temperatury różnica była niezauważalna.

Dane Znormalizowane

Rzeczywista vs Przewidywana Temperatura - MAE: 1.2599999904632568°C



Macierz Konfuzji dla Klasyfikacji Wiatru w Vancouver - Test



Hipoteza: Funkcja ReLU zapewni lepsze wyniki i szybsza zbieżność w porównaniu do funkcji tanh.

Wnioski:

- ReLU była bardziej efektywna.
- Tanh wykazywała wolniejszą zbieżność.

- Normalizacja danych jest szczególnie ważna w klasyfikacji, gdzie różnice w skalach cech mogą wpływać na jakość predykcji.
- Oddzielne modele dla temperatury i wiatru nie wypłynęły na lepsze dopasowanie do specyficznych zadań.
- ReLU pozostaje najlepsza funkcja aktywacji dla większości warstw ukrytych dzięki szybkiej zbieżności i stabilności.
- W przypadku klasyfikacji warto zadbać o zrównoważenie klas w danych wejściowych.

Dziekujemy za uwage!